Команда Сбера

LangChain и Deep Agents

Тращенков Сергей

Разработка и внедрение AI-агентов · МФТИ

Материалы

Telegram-канал

Кто ведёт цикл

Команда Сбера

прошлое занятие

цикл пишете вы

```
history = [вопрос]
while True:
    ответ = модель(history, tools)
    if нет вызовов: break
    for вызов in ответ:
        проверить и исполнить
        history += [вызов, результат]
print(ответ)
```

≈ 15 строк, своя для каждого формата

сегодня

цикл ведёт агент

```
agent = create_agent(
    model=llm,
    tools=[room_tool],
)
agent.invoke({"messages": [вопрос]})
```

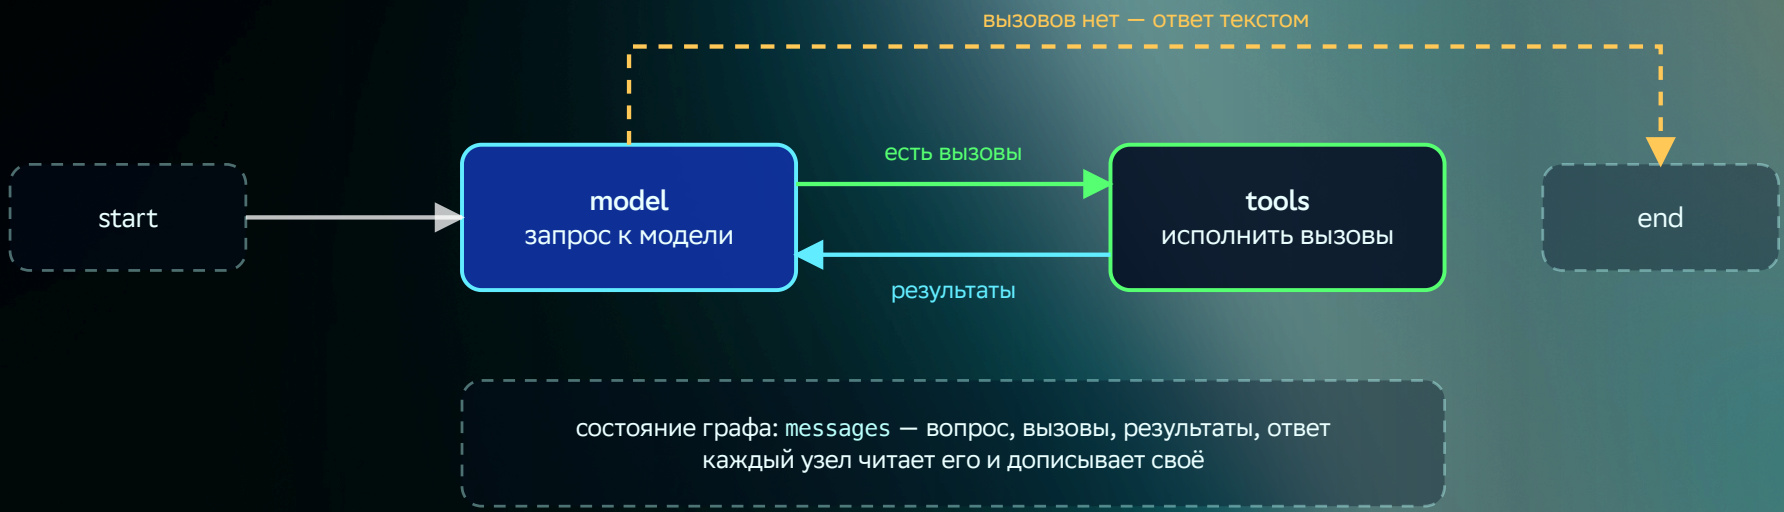
те же шаги: модель → инструменты → модель, пока нет ответа текстом

история, проверки, остановка — в агенте

Материалы

Telegram-канал

Агент — это граф



§ 3.1–3.2

Материалы

Telegram-канал

Память диалога

checkpointer `InMemorySaver()` хранит состояние отдельно для каждого `thread_id`

`thread_id = "rooms-1"`

«Сколько мест в А-101?» → «А проектор там есть?» → «Да, в А-101 есть проектор»

`thread_id = "rooms-2"`

«А проектор там есть?» → «Уточните номер аудитории»

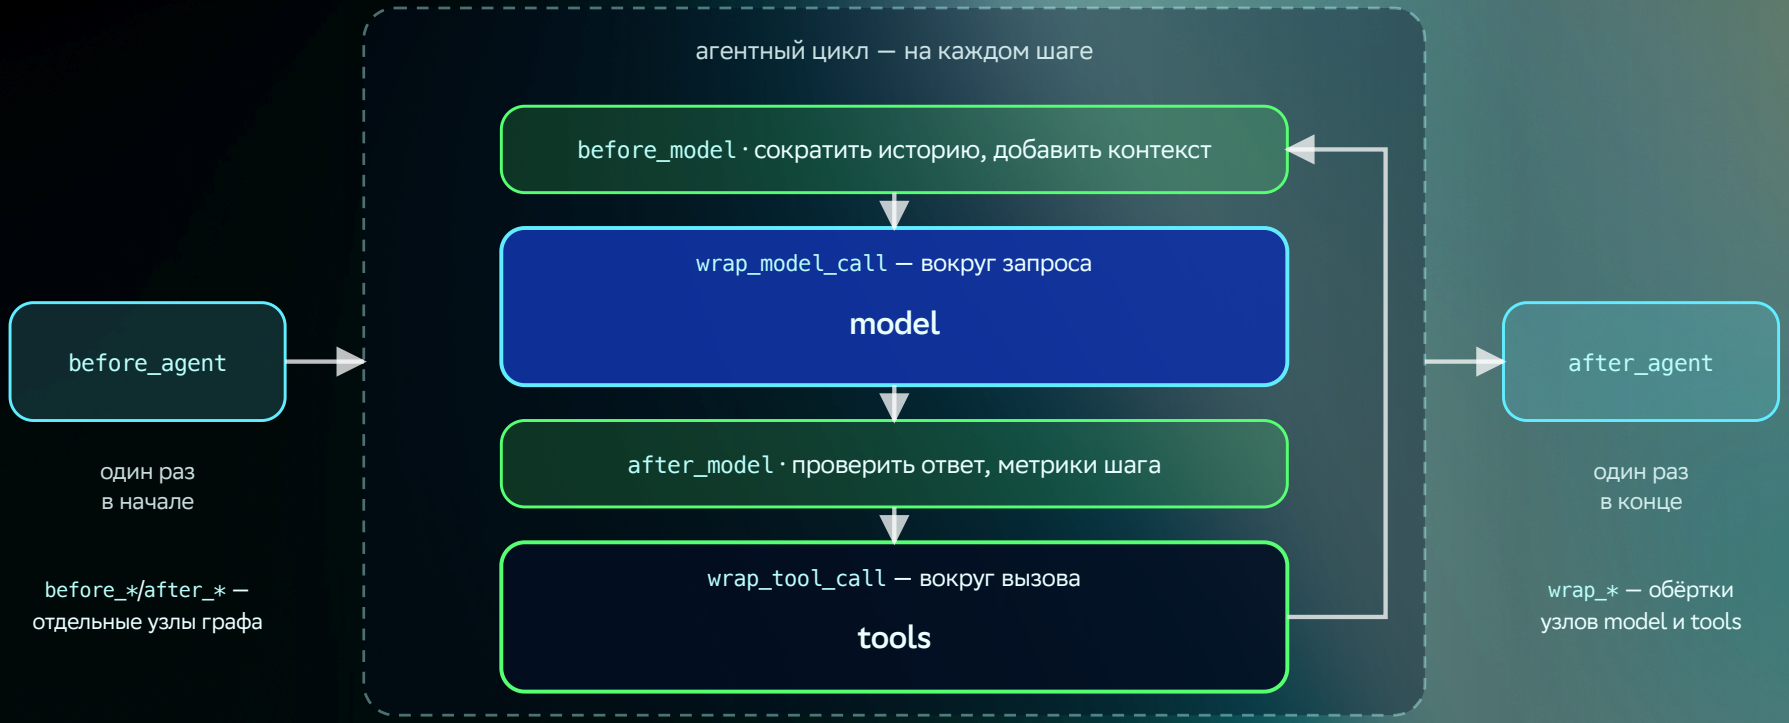
тот же `thread_id` — история продолжается · новый — начинается заново

§ 3.3

Материалы

Telegram-канал

Middleware: где можно вмешаться



Материалы

Telegram-канал

Лимиты на вызовы модели и инструментов

вопрос: «Сравни вместимость A-101 и B-202» — нужно два вызова

`ToolCallLimitMiddleware(run_limit=1)`

→ get_room_info(A-101)

24 места

→ get_room_info(B-202)

«Tool call limit exceeded»

«Не смог узнать про B-202. A-101 — 24 места»

вызов не исполнен, модель отвечает тем, что знает

`ModelCallLimitMiddleware(run_limit=2, exit_behavior="end")`

→ get_room_info(A-101)

24 места

→ get_room_info(B-202)

40 мест

«Model call limits exceeded: run limit (2/2)»

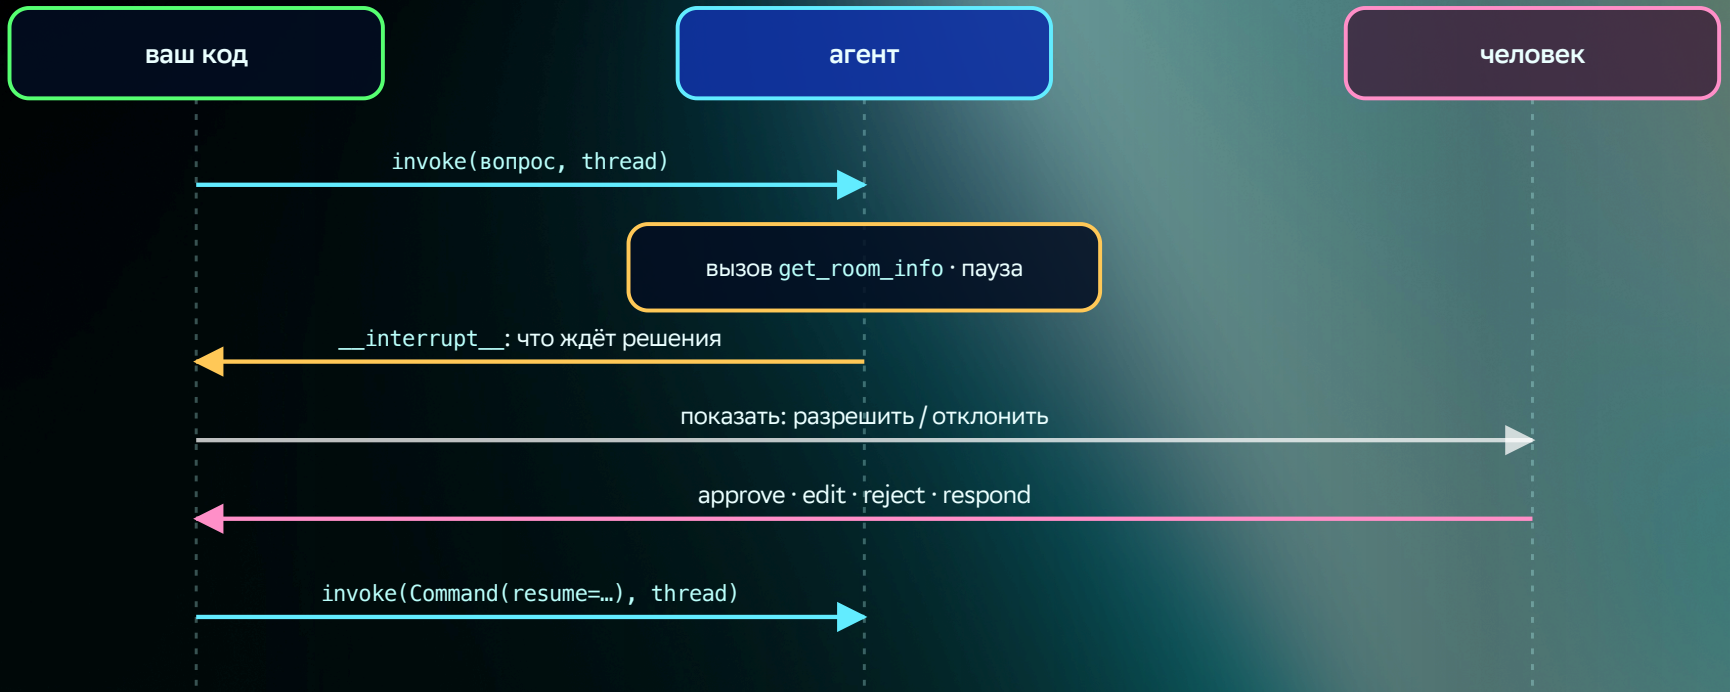
агент остановлен, ответа модели нет

§ 5.1

Материалы

Telegram-канал

Подтверждение человеком



пока человек думает, состояние лежит в checkpointer — без него прерывание не работает

Материалы

Telegram-канал

Особенности GigaChat

что просим	что получаем	как обойти
`tool_choice="any"` — «вызови любую»	адаптер: `ValueError` · API: `422`	middleware: повторить запрос с напоминанием
`SystemMessage` в середине истории	`400` «system message must be the first message»	подсказки по ходу работы — как `HumanMessage`
аргумент `int | str` (`anyOf`)	v2 — принимает · v1 — `{"value": 30}` адаптер — отказ до отправки	middleware: убрать инструмент или упростить схему

Материалы

Telegram-канал

Ловушка: правило на каждом запросе

Команда Сбера

правило на каждом запросе



агент не может закончить работу

правило только до результатов

```
response = handler(request)
if isinstance(request.messages[-1],
              ToolMessage):
    return response  # можно текстом
# иначе: нет вызова → повтор
```

`wrap_model_call` срабатывает на каждом запросе к модели — и на последнем тоже

повтор повышает шанс вызова, окончательно решает модель

§ 6.1

Материалы

Telegram-канал

Обвязка для длинных задач

проблемы длинных задач	что даёт обвязка
контекст переполняется	файлы для промежуточных результатов; субагенты
план теряется	список задач `write_todos`
инструкции не масштабируются	память `AGENTS.md` и skills по требованию
нет рабочей среды	файлы и командная строка `execute`

стек — сверху вниз

Deep Agents
обвязка

LangChain
create_agent · middleware

LangGraph
граф · состояние · прерывания

langchain-core
сообщения · модели · инструменты

§ 7.1

Материалы

Telegram-канал

Deep Agent одной функцией

```
agent = create_deep_agent(
    model=GigaChat(),
    tools=[room_tool],
)
```

профиль GigaChat подключается сам
`[deepagents-gigachat] Harness profile loaded`

системный промпт — около 20 тыс. символов

файлы — `ls` `read_file` `write_file` `edit_file` `delete` `glob` `grep`

командная строка — `execute — если бэкенд позволяет`

субагенты — `task`

от профиля — `think`

ваши — `get_room_info`

в графе — middleware обвязки и профиля:
`LoopBreaker`, `MemoryTask`, `SpecificationAudit`, ...

§ 7.2

Материалы

Telegram-канал

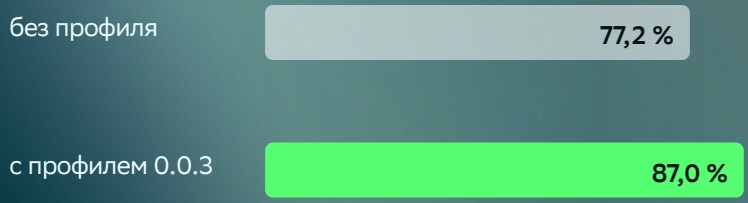
Профиль GigaChat

Команда Сбера

middleware профиля `deepagents-gigachat`

`ThinkTool`	инструмент `think` — рассуждать без действий
`ShellSafety`	блокирует опасные однострочники
`PathNormalizer`	пути в выводе `glob` и `grep`
`MemoryTask`	напоминает про файлы памяти
`LoopBreaker`	3 одинаковых вызова или 3 ошибки подряд → подсказка

391 задача harness-bench-fast · GigaChat 3.5



токены: 7,37 млн → 4,32 млн (−41 %)

профиль: промпты + описания инструментов + middleware под привычки конкретной модели

источник: статья «Профиль GigaChat для Deep Agents»

§ 7.2

Материалы

Telegram-канал

Где живут файлы агента

бэкенд	где файлы	для чего
`StateBackend`	в состоянии графа, `result["files"]`	по умолчанию
`FilesystemBackend`	на диске, в папке `root_dir`	память, отчёты
`LocalShellBackend`	на диске + инструмент `execute`	скрипты, сборка
`StoreBackend`	в LangGraph Store — переживают перезапуск	долгая память
`CompositeBackend`	разные бэкенды для разных путей	`/memories/` → Store

§ 7.3

Материалы

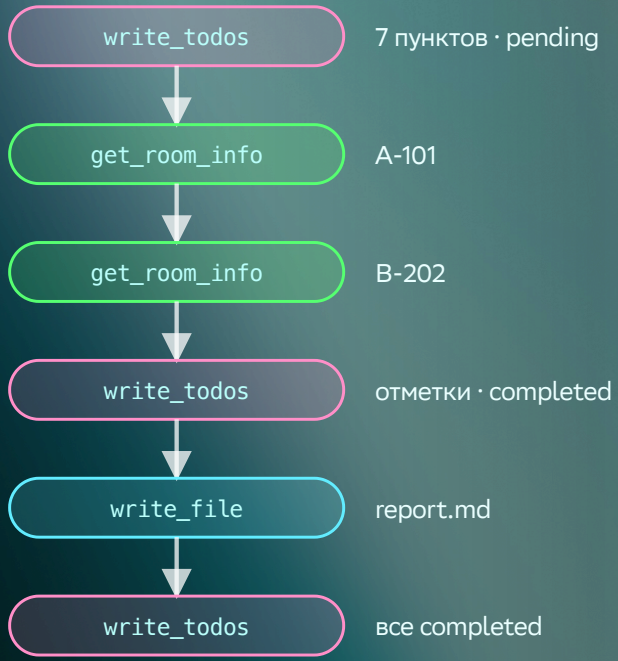
Telegram-канал

План: список задач

```
create_deep_agent(
    model=llm, tools=[room_tool],
    middleware=[TodoListMiddleware()],
)
```

в deepagents 0.7 список задач — по желанию
GigaChat ведёт план, если попросить

план лежит в `result["todos"]` — состоянии,
и переживает сокращение истории



Материалы

Telegram-канал

Командная строка

ваш компьютер

`workspace/ — root_dir`

`write_file("/rooms.py")`

`read_file, edit_file, ls...`

`virtual_mode=True`: файловые инструменты не выйдут из папки

`execute`
`python3 rooms.py`

настоящая командная строка, ваши права

«Итого | 64»
вывод скрипта — агенту

`interrupt_on={"execute": True}`
каждая команда ждёт решения человека

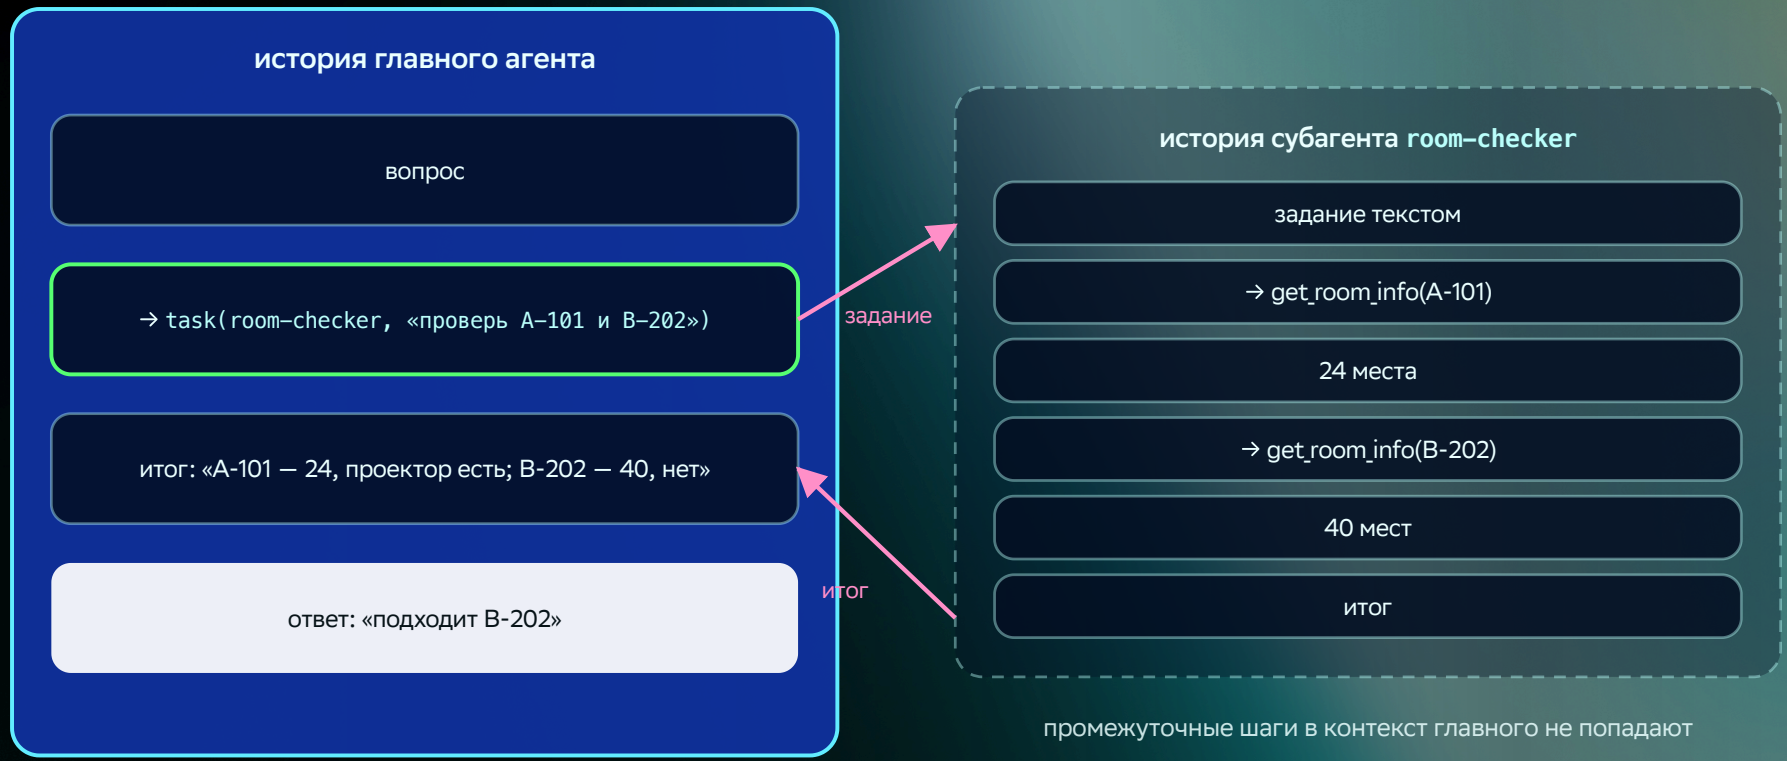
агенту с командной строкой — отдельная папка и подтверждение опасных команд;
в рабочих системах — контейнер или удалённая «песочница»

§ 9

Материалы

Telegram-канал

Субагенты



промежуточные шаги в контекст главного не попадают

Материалы

Telegram-канал

Память и skills

Команда Сбера

память: AGENTS.md

```
# Правила учебной части
- Отвечай одним предложением.
- Номер аудитории — в «ёлочках».
```

↓ в системный промпт

«Группа из 28 человек поместится
в аудитории «В-202»...»

правила проекта · агент может дописывать

`memory=["/AGENTS.md"]`

skills: раскрытие по требованию

в промпте — только индекс:
`room-report`: «Отчёт о подборе аудитории...»

↓ подходит к задаче?

`read_file("/skills/room-report/SKILL.md")`

↓

шаги по инструкции · scripts · references

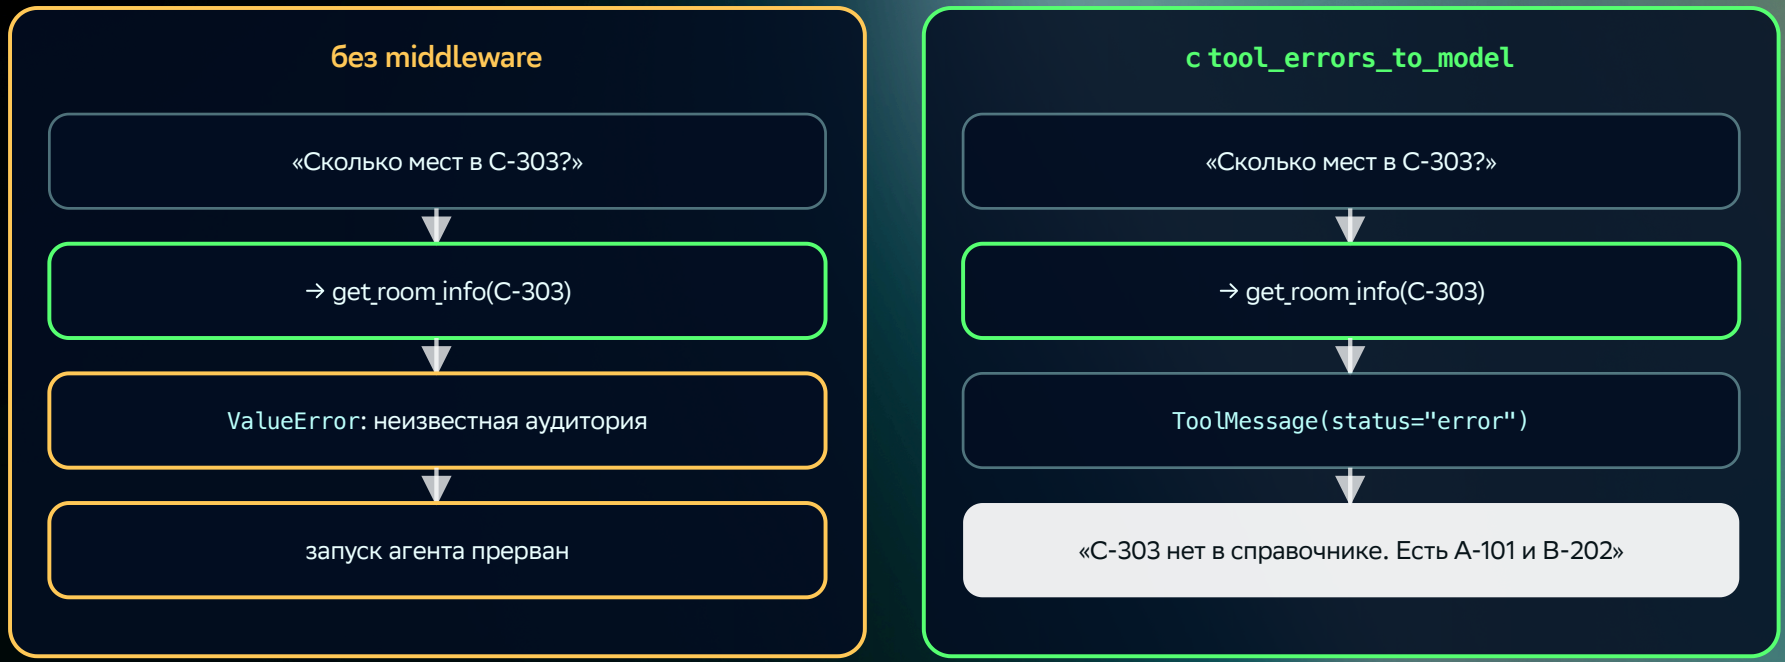
подробно — на занятии о знаниях агента

`skills=["/skills/"]`

Материалы

Telegram-канал

Практика: ошибка инструмента




```
wrap_tool_call: try: handler(request) · except ValueError: return ToolMessage(…)
```


Материалы

Telegram-канал

Что выбрать

Команда Сбера

`create_agent`

- короткие задачи: несколько вызовов
- свои инструменты, своя логика
- middleware — по необходимости
- мало служебных токенов

`create_deep_agent`

- длинные задачи: десятки шагов
- файлы, командная строка, план
- субагенты, память, skills
- готовая обвязка и профиль под модель
- системный промпт ≈ 20 тыс. символов

Материалы

Telegram-канал

Команда Сбера

Вопросы

Материалы

Telegram-канал